

2.1. (线性方程组) Gauss 方法.

1. Gauss 消去法 : 消元回代 $\det A = a_{11} \cdot a_{22}^{(1)} \cdots a_{nn}^{(n-1)}$
2. Gauss 列主元消去法 : 选取列主元 $\max_{k \leq i \leq n} |a_{ik}^{(k-1)}|$ $\det A = a_{11} \cdots a_{in}^{(n-1)}$
3. Gauss 按比例列主元消去法 : 选取列主元 $\max_{k \leq i \leq n} \left| \frac{a_{ik}^{(k-1)}}{s_r} \right|$, $s = \max(\text{行值})$
4. Gauss - Jordan 消去法 : 消元无回代.

2.2. 直接三角分解法.

$$Ax = b \Rightarrow \underbrace{A^{(n-1)}}_{\text{上三角矩阵}} x = b^{(n-1)} \quad \text{其中 } A^{(n-1)} = L_{n-1} \cdot L_{n-2} \cdots L_1 A$$

$$(\text{Gauss 消去法}) L_k = \begin{pmatrix} 1 & & & \\ \vdots & 1 & & \\ & -l_{k+1,k} & 1 & \\ & \vdots & & \ddots \\ & -l_{nk} & & 1 \end{pmatrix}$$

$$\Rightarrow A = \underbrace{L_1^{-1} \cdot L_2^{-1} \cdots L_{n-1}^{-1}}_{\text{L单位: Doolittle}} \underbrace{A^{(n-1)}}_{\text{U单位: Crout}} = L U$$

L 单位: Doolittle
U 单位: Crout

$$\det A = l_{11} \cdots l_{nn} \cdot u_{11} \cdots u_{nn}$$

$$\Rightarrow A = LDR, L, R \text{ 均单位}, D \text{ 对角} \quad \det A = d_1 \cdots d_n.$$

e.g. (Crout 方法)

$$L = \left(\begin{array}{cccc} l_{11} & & & \\ \vdots & \ddots & & \\ l_{n1} & \cdots & l_{nn} \end{array} \right) \quad U = \left(\begin{array}{cccc} u_{11} & \cdots & u_{1n} \\ & \ddots & \\ & & u_{nn} \end{array} \right)$$

step 1. $\Rightarrow LU = A$ 推导即可

$$u_{11}, u_{22} \cdots u_{nn} = 1$$

△ 紧凑的 Crout 方法、按列主元的 Crout 方法.

e.g. Cholesky 分解 [矩阵 A 实对称正定] : $A = L \cdot L^T$

$$L = \begin{pmatrix} l_{11} & & \\ \vdots & \ddots & \\ l_{n1} & \cdots & l_{nn} \end{pmatrix}$$

step 1

e.g. LDL^T 分解 [矩阵 A 实对称正定] : $A = LDL^T$

$$L = \begin{pmatrix} l_{11} & & \\ \vdots & \ddots & \\ l_{n1} & \cdots & l_{nn} \end{pmatrix} \quad D = \begin{pmatrix} d_1 & & \\ & \ddots & \\ & & d_n \end{pmatrix}$$

($l_{11}, l_{22}, \dots, l_{nn} = 1$)

step 1.

e.g. 追赶法 [矩阵 A 三对角，且满足优对角条件] : $A = LU$

$$L = \begin{pmatrix} p_1 & & \\ \vdots & \ddots & \\ a_2 & \cdots & \cdots \\ \vdots & & \\ a_n & p_n \end{pmatrix} \quad U = \begin{pmatrix} 1 & q_1 & & \\ & \ddots & \ddots & \\ & & q_m & \end{pmatrix}$$

step 1.
step 2.
step 3.

2.3. 行列式 & 逆矩阵

$A = [a_{ij}]$, 行列式 $\det A$, 逆矩阵 A^{-1}

e.g. Gauss-Jordan 消去法求逆矩阵

(1). $a_{kk} = c = \frac{1}{a_{kk}}$

(2). $a_{ik} = -c \cdot a_{ik}, i=1 \sim n, \neq k$

(3). $a_{ij} = a_{ij} + a_{ik} \cdot a_{kj}, i,j=1 \sim n, \neq k$

(4). $a_{kj} = c \cdot a_{kj}, j=1 \sim n, \neq k$



#2.4. 向量与矩阵的范数.

$$x = (x_1 \dots x_n)^T \in R^n (C^n)$$

- $\|x\| :$ $\left\{ \begin{array}{l} ① \text{ 非负: } \|x\| > 0 \\ ② \text{ 齐次: } \|\lambda x\| = |\lambda| \|x\| \\ ③ \text{ 三角不等式: } \|x+y\| \leq \|x\| + \|y\| \end{array} \right.$

Define. 矩离: $d(x, y) = \|x - y\|$

Define. l_p 范数 (p -范数): $\|x\|_p = f_p(x) = \left(\sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}}$

↳ 常见: l_1 范数, l_2 范数, l_∞ 范数 ($\|x\|_\infty = \lim_{p \rightarrow \infty} \|x\|_p$)
→ 又叫作 Euclid 范数

$$(x, y) = \sum_{i=1}^n x_i y_i \quad (\text{内积}) \quad \text{即有 } \|x\|_2 = \sqrt{(x, x)}.$$

(另外, 复空间是复 Euclid 空间)

* 性质: $\|x\|_\infty = \max_{1 \leq k \leq n} |x_k|$

$$\text{Prove. } \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}} = \left(|x_{\max}|^p \cdot \sum_{i=1}^n \left| \frac{x_i}{x_{\max}} \right|^p \right)^{\frac{1}{p}} \quad \underset{p \rightarrow \infty \text{ 时}}{\lim_{p \rightarrow \infty}} \left(\sum_{i=1}^n \left| \frac{x_i}{x_{\max}} \right|^p \right)^{\frac{1}{p}} = 1$$

* Cauchy-Schwarz 不等式: $|(x, y)| \leq \|x\|_2 \|y\|_2$

$$\left| \sum_{i=1}^n x_i y_i \right| \leq \left(\sum_{i=1}^n x_i^2 \right)^{\frac{1}{2}} \left(\sum_{i=1}^n y_i^2 \right)^{\frac{1}{2}}$$

R^n 中范数性质:

①. $\|0\| = 0$

②. $\forall x, y \in R^n. \quad | \|x\| - \|y\| | \leq \|x - y\|$

Prov. $\|x\| = \|x + y - y\| \leq \|y\| + \|x - y\| \quad \left. \begin{array}{l} \\ \end{array} \right\} \quad \textcircled{V}$
 $\|y\| = \|y + x - x\| \leq \|x\| + \|x - y\| \quad \left. \begin{array}{l} \\ \end{array} \right\}$

③. $\forall l_p$ 范数都关于 l_2 -致连续：

$$\forall \varepsilon > 0, \exists \delta > 0, \|y - x\|_2 < \delta \text{ 时 } |\|y\|_p - \|x\|_p| < \varepsilon$$

Prov. $\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}} \leq M \|x\|_2 \quad \xrightarrow{\text{Cauchy-Schwarz}}$

$$M = \left(\sum_{i=1}^n \|e_i\|_p^2 \right)^{\frac{1}{2}}$$

$$\Rightarrow |\|y\|_p - \|x\|_p| \leq M \|y - x\|_2 \quad \textcircled{V}$$

④ R^n 中一切向量范数等价： $\forall \|x\|_\alpha, \|x\|_\beta. \exists C_1, C_2 \in R$

$$\text{s.t. } C_1 \|x\|_\beta \leq \|x\|_\alpha \leq C_2 \|x\|_\beta. \quad \forall x \in R^n.$$

2.4.2 矩阵范数

$$\|A\|: \quad \textcircled{1} \|A\| > 0$$

$$\textcircled{2} \|x A\| = |\lambda| \|A\|$$

$$\textcircled{3} \|A + B\| \leq \|A\| + \|B\|$$

$$\textcircled{4} \|AB\| \leq \|A\| \cdot \|B\| \quad (\text{又叫作} \underline{\text{相容条件}})$$

Define 矩阵范数 $\|\cdot\|_\beta$ 与向量范数 $\|\cdot\|_\alpha$ 相容：

$$\forall A \in R^{n \times n}, x \in R^n, \text{ 有 } \|Ax\|_\alpha \leq \|A\|_\beta \cdot \|x\|_\alpha$$

The. $\forall \|\cdot\|_\beta$. 至少有一个 $\|\cdot\|_\alpha$ 与之相容.

Prov. 假设 $\|x\|_\alpha = \|[x, 0, 0 \dots 0]\|_\beta$

$\|x\|_\alpha$ 是 R^n 范数且与 $\|\cdot\|_\beta$ 相容.

Define. $\|A\|_{\beta}$ 从属于 $\|\cdot\|_{\alpha}$: $\forall A \in \mathbb{R}^{n \times n}, \exists x_0 \in \mathbb{R}^n : \|Ax_0\|_{\alpha} = \|A\|_{\beta} \|x_0\|_{\alpha}$

The. $\forall x \in \mathbb{R}^n, A \in \mathbb{R}^{n \times n}, \forall \|\cdot\|_{\alpha}$.
 $\|A\| = \max_{\|x\|_{\alpha}=1} \|Ax\|_{\alpha}$
 是从属于 $\|\cdot\|_{\alpha}$ 的矩阵范数. 称为算子范数.

Prov. 分条验证: 1. $\|A\|$ 是矩阵范数. 2. 满足从属性.

* 在上述 The. 中. $\|\cdot\|_{\alpha}$ 分别取 l_1, l_2, l_{∞} , 得到的算子范数:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

$\|A\|_2 = \sqrt{\lambda_1}$, λ_1 是 $A^T A$ 最大特征值. (又称谱范数)

$$\|A\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

$$(\text{Frobenius 范数}) \quad \|A\|_F = \left(\sum_{i,j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}}$$

$\mathbb{R}^{n \times n}$ 中矩阵范数性质.:

- ① $\|0\| = 0$
- ② $|\|A\| - \|B\|| \leq \|A - B\|$
- ③ $\|A\|_{\alpha}$ 关于 $\|\cdot\|_{\beta}$ -致连续
- ④ $\forall \|A\|_{\alpha}, \|A\|_{\beta}$ 等价.

$\mathbb{R}^{n \times n}$ 范数亦可推广至 $m \times n$ (类比) ...

Define. 谱半径: $\rho(A) = \max_{i=1 \sim n} |\lambda_i|$, λ_i 是 A 的特征值.

The. 2.4.3 ~ 2.4.5 (Page. 70 ~ 71)

2.5 误差分析.

Define. 条件数 $\text{Cond}(A) = \|A\| \cdot \|A^{-1}\|$

$$\text{特别地: } \text{Cond}(A)_2 = \kappa(A) = \|A\|_2 \|A^{-1}\|_2$$

$$\text{Cond}(A)_\infty = \|A\|_\infty \cdot \|A^{-1}\|_\infty$$

性质: ① $\text{Cond}(A) > 0$ ② $\text{Cond}(A) = \text{Cond}(KA)$

$$③ \text{Cond}(A^{-1}) = \text{Cond}(A)$$

$$④ \text{Cond}(AB) \leq \text{Cond}(A) \cdot \text{Cond}(B).$$

2种扰动情况: $Ax = b$

1. 右侧扰动: $A(x + \delta x) = b + \delta b$

$$\hookrightarrow \frac{\|\delta x\|}{\|x\|} \leq \text{Cond}(A) \cdot \frac{\|\delta b\|}{\|b\|}$$

(相对误差上界)

2. 左侧扰动: $(A + \delta A)(x + \delta x) = b$

$$\hookrightarrow \frac{\|\delta x\|}{\|x\|} \leq \frac{\text{Cond } A (\|\delta A\| / \|A\|)}{1 - \text{Cond } A (\|\delta A\| / \|A\|)}$$

